

EST0023 - PROBABILIDADE E ESTATÍSTICA

Unidade V - Parte II (Amostragem e TCL)

José Augusto Fiorucci

Departamento de Estatística
Universidade de Brasília

Noções de Amostragem

Distribuição da média amostral e distribuição da soma amostral

Aproximação da Binomial pela Normal

Distribuição da proporção amostral

Noções de Amostragem

Amostra aleatória

Def.: Uma sequência $X_1, \dots, X_n$ de variáveis aleatórias *independentes e identicamente distribuídas* (i.i.d.) com função de probabilidade (caso discreto) ou função de densidade de probabilidade (caso contínuo) $f(x; \theta)$ é dita ser uma **amostra aleatória** (a.a.) de tamanho “n” da v.a. X .

- ▶ nesse contexto, a v.a. X faz referência a uma característica populacional.
- ▶ θ denota o vetor de parâmetros desconhecidos relacionados a X .
- ▶ Como a amostra aleatória $X_1, \dots, X_n$ é i.i.d. então a distribuição conjunta pode ser encontrada facilmente, pois

$$f(x_1, \dots, x_n; \theta) = f(x_1; \theta) \times f(x_2; \theta) \times \dots \times f(x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

- ▶ OBS: esse resultado é obtido apenas expandindo o conceito de variáveis independentes bidimensionais para o caso n-dimensional;

Principais medidas descritivas

Seja $X_1, X_2, \dots, X_n$ uma a.a. de tamanho n da v.a. X . Definimos então:

- ▶ **Média amostral:** descreve o ponto de equilíbrio da amostra, geralmente denotada com uma barra sobre a variável ($\bar{X}$)

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n}$$

- ▶ **Variância amostral:** descreve o nível de dispersão dos dados em relação a média na escala quadrática, geralmente denotada por S^2

$$S^2 = \frac{(X_1 - \bar{X})^2 + (X_2 - \bar{X})^2 + \dots + (X_n - \bar{X})^2}{n - 1} = \frac{1}{n - 1} \sum_{i=1}^n (X_i - \bar{X})^2$$

- ▶ **Desvio padrão amostral:** descreve o nível de dispersão dos dados em relação a média na escala original, geralmente denotado por S

$$S = \sqrt{\frac{1}{n - 1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

- ▶ Exemplo: suponha que 7 alunos da turma foram sorteados para formar uma amostra das idades dos alunos e os valores observados foram 20, 19, 21, 23, 22, 18, 20. Os valores observados então foram:

- ▶ Média amostral: $\bar{x} = 143/7 \approx 20.43$ anos

- ▶ Variância amostral:

$$s^2 = [(-0.43)^2 + (-1.43)^2 + (0.57)^2 + (2.57)^2 + (1.57)^2 + (-2.43)^2 + (-0.43)^2] / 6 \approx 2.95 \text{ anos}^2$$

- ▶ Desvio padrão amostral: $s = \sqrt{2.95} \approx 1.72$ anos

- ▶ Note que, ainda que esses sejam os valores observados dessas medidas para a amostra que foi observada, em um novo sorteio, outros valores poderiam ser encontrados para essas medidas. Ou seja, $\bar{X}$, S^2 e S também são variáveis aleatórias e devemos estudar suas propriedades.

Propriedades

Seja $X_1, \dots, X_n$ uma a.a. da v.a. X que possui média $\mu = E[X]$ (“média populacional”) e variância $\sigma^2 = Var[X]$ (“variância populacional”), então:

- i) O valor esperado da média amostral ($\bar{X}$) é igual ao valor esperado de X :

$$E[\bar{X}] = \mu$$

- ii) A variância da média amostral ($\bar{X}$) é igual a variância de X dividida pelo tamanho da amostra

$$Var[\bar{X}] = \frac{\sigma^2}{n}$$

- iii) O valor esperado da variância amostral (S^2) é igual a variância de X

$$E[S^2] = \sigma^2$$

Demonstração das propriedades

Como $X_1, \dots, X_n$ são i.i.d., segue que:

- i) $E[\bar{X}] = E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{1}{n} \sum_{i=1}^n \mu = \mu$
- ii) $Var[\bar{X}] = Var\left[\frac{1}{n} \sum_{i=1}^n X_i\right] \stackrel{\text{indep.}}{=} \frac{1}{n^2} \sum_{i=1}^n Var[X_i] = \frac{1}{n^2} \sum_{i=1}^n \sigma^2 = \frac{\sigma^2}{n}$
- iii)

$$\begin{aligned} E[S^2] &= E\left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right] = \frac{1}{n-1} \sum_{i=1}^n E\left[\left[(X_i - \mu) - (\bar{X} - \mu)\right]^2\right] \\ &= \frac{1}{n-1} \sum_{i=1}^n E\left[(X_i - \mu)^2 - 2(X_i - \mu)(\bar{X} - \mu) + (\bar{X} - \mu)^2\right] \\ &= \frac{1}{n-1} \sum_{i=1}^n \left[\underbrace{E[(X_i - \mu)^2]}_{Var[X_i] = \sigma^2} - 2 \underbrace{E[(X_i - \mu)(\bar{X} - \mu)]}_{\frac{1}{n} Cov(X_i, X_i) = \sigma^2/n} + \underbrace{E[(\bar{X} - \mu)^2]}_{Var[\bar{X}] = \sigma^2/n} \right] \\ &= \frac{1}{n-1} \sum_{i=1}^n \left[\frac{(n-1)}{n} \sigma^2 \right] \\ &= \sigma^2 \end{aligned}$$

Exemplo

Exemplo (controle de qualidade, 6 sigma): uma máquina deve encher latas de tinta com média de 128 onças e desvio padrão de 0.2 onças. Em um teste com 40 latas amostradas aleatoriamente, foi encontrado média amostral igual a 127.5 onças. Considerando 3 desvios padrões de tolerância para a média amostral, verifique se a máquina esta operando de modo adequado.

Solução:

- ▶ Para 1 lata (X):
 - ▶ Média teórica: $\mu = 128$
 - ▶ Variância teórica: $\sigma^2 = 0.2^2 = 0.04$
- ▶ Para a média de 40 latas ($\bar{X}$):
 - ▶ Média teórica: $\mu_{\bar{X}} = 128$
 - ▶ Variância teórica: $\sigma_{\bar{X}}^2 = \frac{\sigma^2}{n} = \frac{0.04}{40} = 0.001$
 - ▶ Desvio padrão teórico: $\sigma_{\bar{X}} = \sqrt{0.001} = 0.0316$
- ▶ Tolerância para $\bar{X}$: $\mu_{\bar{X}} \pm 3 \sigma_{\bar{X}} = (127.905, 128.095)$
- ▶ Conclusão: como a média observada 127.5 esta fora da tolerância, então a máquina deve ser reajustada.

Distribuição da média amostral e distribuição da soma amostral

Média de Normais

Como consequência direta das propriedades de “soma de normais” e “transformação linear de normais”, ambas vistas na Unidade IV, temos o seguinte teorema:

- **Teorema:** Seja $X_1, \dots, X_n$ uma a.a. da v.a. $X \sim \text{Normal}(\mu, \sigma^2)$, então a média amostral também tem distribuição normal, isto é,

$$\bar{X} = \left(\frac{1}{n} \sum_{i=1}^n X_i \right) \sim \text{Normal}(\mu_{\bar{X}}; \sigma_{\bar{X}}^2),$$

em que $\mu_{\bar{X}} = \mu$ e $\sigma_{\bar{X}}^2 = \sigma^2 / n$.

- Resulta desse teorema que:

$$Z = \left(\frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \right) \sim \text{Normal}(0; 1)$$

Soma de Normais

Teorema: Seja $X_1, \dots, X_n$ uma a.a. da v.a. $X \sim \text{Normal}(\mu, \sigma^2)$, então a soma amostral também tem distribuição normal, isto é,

$$S_n = \left(\sum_{i=1}^n X_i \right) \sim \text{Normal}(n\mu, n\sigma^2).$$

- **Obs (visto na Unidade IV):** um resultado ainda mais geral que pode ser demonstrado é que a soma de v.a.'s Normais sempre é Normal. Em particular, seja $X_1, X_2, \dots, X_n$ variáveis aleatórias independentes com distribuição de probabilidade Normal, com as respectivas médias $\mu_1, \mu_2, \dots, \mu_n$ e respectivas variâncias $\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2$, então

$$S_n = \left(\sum_{i=1}^n X_i \right) \sim \text{Normal}(\mu_1 + \mu_2 + \dots + \mu_n, \sigma_1^2 + \sigma_2^2 + \dots + \sigma_n^2)$$

Teorema do Limite Central (TCL)

- ▶ Os resultados dos slides anteriores estão limitados a quando a amostra aleatória é originada de uma v.a. com distribuição Normal. No entanto, felizmente, pode-se mostrar que para amostras “suficientemente grandes”, a distribuição de probabilidade da média amostral (e também da soma amostral) pode ser aproximada por uma distribuição Normal.
- ▶ Este fato, é um dos teoremas mais importantes da Estatística e é denominado **Teorema do Limite Central (TCL)**.
- ▶ Neste caso, dizemos que a Normal é a distribuição assintótica (válida quando $n \rightarrow \infty$);

Teorema do Limite Central (TCL)

Teorema do Limite Central: Seja $X_1, \dots, X_n$ uma a.a. retirada de uma população com média μ e variância σ^2 , então

i) $\bar{X} = \left(\frac{1}{n} \sum_{i=1}^n X_i \right) \sim^a \text{Normal}(\mu ; \sigma^2/n);$

ii) $S_n = (\sum_{i=1}^n X_i) \sim^a \text{Normal}(n\mu ; n\sigma^2).$

► **Proposição:** Segue diretamente do teorema que

i) $Z = \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right) \sim^a \text{Normal}(0 ; 1);$

ii) $Z = \left(\frac{S_n - n\mu}{\sqrt{n} \sigma} \right) \sim^a \text{Normal}(0 ; 1).$

Teorema do Limite Central (TCL)

- ▶ Quanto maior o tamanho da amostra, melhor é a aproximação;
- ▶ Estudos de simulação indicam que a aproximação é boa, na maior parte dos casos, já a partir de $n = 30$;

Exemplo

Seja X : “o peso em kg de alunos homens de um escola”. Suponha que não conhecemos a distribuição de X , mas sabemos que a média é $\mu = E[X] = 70 \text{ kg}$ e a variância $\sigma^2 = \text{Var}[X] = 16 \text{ kg}^2$. Se selecionado aleatoriamente um grupo de 36 alunos, qual a probabilidade da média amostral ser maior que 71 kg?

Solução:

- Pelo Teorema do limite central

$$Z = \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right) = \left(\frac{\bar{X} - 70}{4/6} \right) \sim^a \text{Normal}(0, 1)$$

- Então

$$\begin{aligned} P(\bar{X} > 71) &= P\left(\frac{\bar{X} - 70}{4/6} > \frac{71 - 70}{4/6} \right) \\ &= P(Z > 1.5) = 1 - P(Z < 1.5) = 1 - \Phi(1.5) \\ &= 1 - 0.93319 = 0.06681 \end{aligned}$$

Exercício

Nas condições do exemplo do slide anterior determine a probabilidade da soma ser maior que 2500 kg.

► Resposta: 0.79673

Aproximação da Binomial pela Normal

Aproximação da Binomial pela Normal

Seja $Y \sim \text{Binomial}(n, p)$, logo

$$E[Y] = np \quad \text{e} \quad \text{Var}[Y] = np(1 - p)$$

Também sabemos que por definição Y consiste na soma de “n” v.a.’s independentes com distribuição de Bernoulli(p), isto é,

$$Y = X_1 + X_2 + \cdots + X_n$$

em que $X_1, \dots, X_n$ são i.i.d. com $X_i \sim \text{Bernoulli}(p)$.

Aproximação da Binomial pela Normal

Assim para “ n ” suficientemente grande, o teorema do limite central afirma que

$$Y \sim^a \text{Normal}(np, np(1-p))$$

ou equivalentemente,

$$Z = \left(\frac{Y - np}{\sqrt{np(1-p)}} \right) \sim^a \text{Normal}(0, 1)$$

- OBS: essa aproximação pode não ser adequada para valores extremos de p ($p \approx 0$ ou $p \approx 1$), especialmente se n não for muito grande.

Exemplo

Estudos indicam que 30% dos funcionários de bancos sofrem com altos níveis de estresse. Numa amostra aleatória de 200 bancários, qual a probabilidade de encontrar 50 ou mais com esse problema?

Solução:

- ▶ Seja X o número de funcionários com o problema na amostra, logo

$$X \sim \text{Binomial}(n = 200, p = 0.3)$$

e portanto, $P[X = x] = \binom{n}{x} p^x (1 - p)^{(n-x)} = \binom{200}{x} 0.3^x 0.7^{200-x}$.

- ▶ Cálculo via a Binomial:

$$P[X \geq 50] = \sum_{k=50}^{200} \binom{200}{k} 0.3^k 0.7^{200-k} \quad (\text{difícil de ser calculado})$$

Exemplo - continuação

► Cálculo via TCL:

► Média: $E[X] = np = 200 * 0.3 = 60$

► Variância: $Var[X] = np(1 - p) = 200 * 0.3 * 0.7 = 42$

► Aproximação:

$$\begin{aligned} P(X \geq 50) &= P\left(\frac{X - 60}{\sqrt{42}} \geq \frac{50 - 60}{\sqrt{42}}\right) \\ &= P(Z \geq -1.54) \\ &= P(Z \leq 1.54) \\ &= \Phi(1.54) = 0.93822 \end{aligned}$$

Distribuição da proporção amostral

Distribuição da proporção amostral

- ▶ Considere uma população em que a **proporção** de indivíduos com certa característica é p .
- ▶ Seja X a v.a. que indica se um indivíduo qualquer possui essa característica, logo

$$X \sim \text{Bernoulli}(p)$$

e sabemos que $E[X] = p$ e $\text{Var}[X] = p(1 - p)$.

Distribuição da proporção amostral

- ▶ Em uma amostra aleatória $X_1, \dots, X_n$ dessa população, seja $\hat{p}$ a proporção amostral dos indivíduos com essa característica, logo

$$\hat{p} = \frac{X_1 + \dots + X_n}{n} = \bar{X}$$

ou seja, a proporção amostral corresponde a média amostral de variáveis Bernoullis $\hat{p} = \bar{X}$. Logo,

- ▶ a média da proporção amostral é dada por

$$E[\hat{p}] = E[\bar{X}] = E[X] = p$$

- ▶ a variância da proporção amostral é dada por

$$\text{Var}[\hat{p}] = \text{Var}[\bar{X}] = \frac{\text{Var}[X]}{n} = \frac{p(1-p)}{n}$$

Distribuição da proporção amostral

- Pelo TCL, temos então

$$\hat{p} \sim^a Normal(p, p(1-p)/n)$$

ou equivalentemente,

$$Z = \left(\frac{\hat{p} - p}{\sqrt{p(1-p)/n}} \right) \sim^a Normal(0, 1)$$

Exemplo

Suponha que 60% da população de uma cidade seja a favor da criação de um fundo público para fins de instalação de uma área de lazer. Se 150 pessoas são selecionadas aleatoriamente, qual a probabilidade de que a proporção amostral seja inferior a 52%?

Solução:

- ▶ Primeiramente note que a proporção populacional é $p = 0.6$
- ▶ Denotemos por $\hat{p}$ a proporção amostral (percentual de pessoas dentro da amostra que são favoráveis)
 - ▶ Média: $E[\hat{p}] = p = 0.6$
 - ▶ Variância: $Var[\hat{p}] = p(1 - p)/n = 0.6 * 0.4/150 = 0.0016$

Exemplo - continuação

► Aproximação via TCL:

$$\begin{aligned}P(\hat{p} < 0.52) &= P\left(\frac{\hat{p} - 0.6}{\sqrt{0.0016}} < \frac{0.52 - 0.6}{\sqrt{0.0016}}\right) \\&= P(Z < -2) \\&= \Phi(-2) \\&= 1 - \Phi(2) \\&= 1 - 0.97725 = 0.02275\end{aligned}$$

Exemplo

Suponha que $p = 30\%$ dos estudantes de uma escola sejam mulheres. Em uma a.a. de 30 alunos, considere $\hat{p}$ como sendo a proporção de mulheres, então determine utilizando TCL qual a probabilidade de que $\hat{p}$ difira de p em menos que 0.01.

Solução:

- primeiramente note que

$$Var[\hat{p}] = p(1 - p)/n = 0.3 * 0.7/30 = 0.007,$$

Exemplo - continuação

- Utilizando o TCL:

$$\begin{aligned}P(|p - \hat{p}| < 0.01) &= P(-0.01 < p - \hat{p} < 0.01) \\&= P\left(\frac{-0.01}{\sqrt{0.007}} < \frac{p - \hat{p}}{\sqrt{0.007}} < \frac{0.01}{\sqrt{0.007}}\right) \\&= P(-0.12 < Z < 0.12) \\&= P(Z < 0.12) - P(Z < -0.12) \\&= \Phi(0.12) - \Phi(-0.12) \\&= \Phi(0.12) - [1 - \Phi(0.12)] \\&= 2\Phi(0.12) - 1 \\&= 2 * 0.54776 - 1 \\&= 0.09552\end{aligned}$$