

EST0023 - PROBABILIDADE E ESTATÍSTICA

Unidade VI

José Augusto Fiorucci

Departamento de Estatística
Universidade de Brasília

Inferência - Introdução

Estimação Pontual

Estimação Pontual - Método dos Momentos

Estimação Pontual - Máxima Verossimilhança


Estimação Intervalar (intervalo de confiança)

Estimação Intervalar - Média Populacional

Estimação Intervalar - Proporção Populacional

Inferência - Introdução

Inferência - Introdução



Inferência - Introdução

- ▶ **Inferência estatística:** refere-se ao uso apropriado de uma amostra da população para se ter conhecimento sobre os parâmetros da população;
- ▶ **Parâmetro:** característica numérica da população, em geral desconhecida, para a qual temos interesse. Exemplo: Média (μ), Variância (σ^2), Proporções (p), Taxas (λ), etc;
- ▶ **Estatística:** qualquer função da amostra $T(X_1, \dots, X_n)$ é chamada de estatística. Exemplo: média amostral, variância amostral, proporção amostral, etc.
- ▶ **Estimador:** um estimador é uma estatística que possibilita obter informação a respeito de um determinado parâmetro. Geralmente são denotados como sendo o parâmetro com chapéu. Por exemplo:
 - ▶ a média amostral ($\hat{\mu} = \bar{X}$) é um estimador da média populacional (μ);
 - ▶ a variância amostral ($\hat{\sigma}^2 = S^2$) é um estimador da variância populacional (σ^2);
 - ▶ a proporção amostral ($\hat{p} = n_1/n$) é um estimador da proporção populacional (p);

Inferência - Introdução

- ▶ **amostra observada:** consiste nos valores observados na amostra, geralmente denotados pelas mesmas letras da v.a., mas minúsculas. Por exemplo, se X é a variável aleatória, então $X_1, \dots, X_n$ denota uma a.a. qualquer da v.a. X e $x_1, \dots, x_n$ denota a amostra que de fato foi observada;
- ▶ **Estimativa:** a estimativa consiste no valor do estimador obtido para a amostra observada;

Exemplo

Suponha que uma pesquisa eleitoral ouviu 2500 eleitores, escolhidos aleatoriamente, a respeito da intenção deles votarem no candidato A. Se 1500 responderam que pretendem votar em A, determine a população, a amostra, o parâmetro de interesse, o estimador e a estimativa.

- ▶ População: todos os eleitores;
- ▶ Variável: $X \sim \text{Bernoulli}(p)$;
- ▶ Parâmetro de interesse:
 - ▶ p : proporção da população que irá votar em A;
- ▶ Amostra: 2500 ouvidos na pesquisa $(X_1, \dots, X_{2500})$;
- ▶ Estimador:
 - ▶ $\hat{p} = n_1/n$, em que $n_1 = X_1 + \dots + X_{2500}$ é número de eleitores que vão votar em A dentro da amostra e $n = 2500$ é tamanho da amostra;
- ▶ Estimativa:
 - ▶ na amostra foi observado $n_1 = 1500$ e $n = 2500$, logo a estimativa é $\hat{p} = 1500/2500 = 0.6$.

Estimação Pontual

Características de um estimador

- ▶ Podem existir vários estimadores para um parâmetro;
- ▶ Existem técnicas para decidir qual estimador é o mais adequado;
 - ▶ Esses critérios não fazem parte da ementa da disciplina;
- ▶ Interessados em aprofundar no assunto podem consultar os tópicos abaixo no livro texto:
 - ▶ **Viés (vício):** o viés é definido como o erro médio do estimador. Se θ é o parâmetro de interesse e $\hat{\theta}$ é o estimador, então $Viés = \theta - E[\hat{\theta}]$.
 - ▶ é desejável que o estimador em média não apresente erro, ou seja, tenha viés igual a zero;
 - ▶ **Variância:** é desejável que o estimador apresente a menor variabilidade possível, ou seja, apresente valores semelhantes em diferentes amostras. Quanto menor $Var[\hat{\theta}]$, então melhor é o estimador;
 - ▶ **Consistência:** Um estimador $\hat{\theta}$ é consistente para estimar θ , se para $\varepsilon > 0$ arbitrário, então $\lim_{n \rightarrow \infty} P(|\hat{\theta} - \theta| > \varepsilon) = 0$.
 - ▶ é desejável que quanto maior o tamanho da amostra, então mais próximo do valor real esteja o estimador;

Exemplo viés de estimador

Exercício: Compare o viés do estimador $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ com o viés do estimador $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$. Lembre que ambos são estimadores de $\sigma^2 = \text{Var}[X]$. Utilize que $E[S^2] = \sigma^2$ (demonstrado na Unidade V).

► Solução:

► Como $\hat{\sigma}^2 = \frac{n-1}{n} S^2$, então

$$E[\hat{\sigma}^2] = \frac{n-1}{n} E[S^2] = \frac{n-1}{n} \sigma^2$$

► Logo,

$$\text{Viés}(\hat{\sigma}^2) = \sigma^2 - E[\hat{\sigma}^2] = \sigma^2/n$$

mas,

$$\text{Viés}(S^2) = \sigma^2 - E[S^2] = 0$$

► Conclusão: o estimador $\hat{\sigma}^2$ é viesado para σ^2 , mas o estimador S^2 é não viesado para σ^2 . Por conta disso, o S^2 é geralmente adotado como o principal estimador do parâmetro σ^2 .

Estimação Pontual - Método dos Momentos

Estimador do Método dos Momentos

- ▶ Seja X uma v.a. com f.d.p. (ou f.p. se discreta) $f(x; \theta)$, em que $\theta = (\theta_1, \theta_2, \dots, \theta_k)'$ é o vetor de tamanho k dos parâmetros desconhecidos.
- ▶ Seja $X_1, \dots, X_n$ uma a.a. de X . Definimos os k primeiros momentos amostrais como:

$$m_j = \frac{1}{n} \sum_{i=1}^n X_i^j, \quad j = 1, 2, \dots, k.$$

- ▶ Enquanto que os momentos teóricos (populacionais) são definidos como:

$$\mu_j = E[X^j], \quad j = 1, 2, \dots, k.$$

Estimador do Método dos Momentos

Def.: dizemos que $\hat{\theta}_1, \dots, \hat{\theta}_k$ são os estimadores obtidos pelo **método dos momentos** (MM) para os parâmetros $\theta_1, \theta_2, \dots, \theta_k$, respectivamente, se eles forem solução do sistema de equações

$$\begin{cases} \mu_1 = m_1 \\ \mu_2 = m_2 \\ \vdots \\ \mu_k = m_k \end{cases}$$

Exemplo 1

Seja $X \sim \text{Exp}(\lambda)$ em que λ é desconhecido. Suponha que uma amostra aleatória de X de tamanho 5 obteve os seguintes valores 3.5; 6.0; 5.2; 2.1; 4.2. Determine a estimativa de λ pelo MM.

► Solução:

- Sabemos que $E[X] = 1/\lambda$ (Primeiro momento teórico).
- O primeiro momento amostral é $m_1 = \bar{X} = (1/n) \sum_{i=1}^n X_i$.
- Igualando o momento teórico com o momento amostral temos:

$$1/\lambda = \bar{X}$$

- ou seja, o estimador de momentos para λ é $\hat{\lambda} = 1/\bar{X}$.
- Como o primeiro momento observado é $\bar{x} = (3.5 + 6.0 + 5.2 + 2.1 + 4.2)/5 = 4.2$, logo a **estimativa** de λ é

$$\hat{\lambda} = 1/4.2 = 0.2380952$$

Exemplo 2

Seja $X \sim \text{Normal}(\mu, \sigma^2)$ em que μ e σ^2 são ambos desconhecidos. Suponha que uma amostra aleatória de X de tamanho 5 obteve os seguintes valores 3.5; 6.0; 5.2; 2.1; 4.2. Determine a estimativa pelo MM de μ e σ^2 .

► Solução:

► Momentos teóricos:

$$\mu_1 = E[X] = \mu$$

$$\mu_2 = E[X^2] = \text{Var}[X] + E[X]^2 = \sigma^2 + \mu^2$$

► Momentos amostrais observados:

$$m_1 = \frac{1}{n} \sum_{i=1}^n X_i = (3.5 + 6.0 + 5.2 + 2.1 + 4.2)/5 = 4.2$$

$$m_2 = \frac{1}{n} \sum_{i=1}^n X_i^2 = (3.5^2 + 6.0^2 + 5.2^2 + 2.1^2 + 4.2^2)/5 = 19.468$$

Exemplo - continuação

- Sistema de equações:

$$\begin{cases} \mu_1 = m_1 \\ \mu_2 = m_2 \end{cases} \Rightarrow \begin{cases} \mu = 4.2 \\ \sigma^2 + \mu^2 = 19.468 \end{cases}$$

- Logo, a solução do sistema nos dá as estimativas $\hat{\mu} = 4.2$ e $\hat{\sigma}^2 = 19.468 - 4.2^2 = 1.828$.

- ▶ Apesar de simples, na prática os estimadores de MM são pouco utilizados.
- ▶ Não raramente o estimador MM não é único, o que é uma característica não desejável na inferência estatística.
- ▶ O Estimador de Máxima Verossimilhança (será visto nos próximos slides) é o mais utilizado na prática.

Estimação Pontual - Máxima Verossimilhança

Estimador de Máxima Verossimilhança

Def.: Seja X uma v.a. com f.d.p. (ou f.p. se discreta) $f(x; \theta)$, em que θ é o vetor de parâmetros desconhecidos.

Se $\mathbf{x} = (x_1, \dots, x_n)'$ é o valor observado da amostra aleatória, a **função de verossimilhança** é definida como sendo a distribuição conjunta calculada no ponto $\mathbf{x}$, isto é,

$$L(\theta) := \prod_{i=1}^n f(x_i; \theta)$$

- ▶ Note que, uma vez que $\mathbf{x}$ é um valor fixo (por ser conhecido), a função de verossimilhança é dependente apenas do parâmetro θ .
- ▶ A seguir, em muitas situações vamos utilizar o logaritmo da verossimilhança, este será denotado por $\ell(\theta)$, ou seja,

$$\ell(\theta) := \log(L(\theta)) = \sum_{i=1}^n \log(f(x_i; \theta))$$

Estimador de Máxima Verossimilhança

Def.: Um **Estimador de Máxima Verossimilhança** (EMV), $\hat{\theta}$ do parâmetro θ , caso exista, é o valor que maximiza $L(\theta)$, isto é,

$$\hat{\theta} = \arg \max_{\theta} L(\theta)$$

ou equivalentemente, uma vez que a função logaritmo é monotona crescente,

$$\hat{\theta} = \arg \max_{\theta} \ell(\theta)$$

Dicionário: *verossímil é aquilo que parece verdadeiro, que é plausível. O termo indica que algo faz sentido e é coerente com a lógica, mesmo que não seja um fato comprovado.*

Estimador de Máxima Verossimilhança

Se $L(\theta)$ é diferenciável em $\theta \in \Theta$, em que Θ denota o espaço paramétrico (conjunto dos possíveis valores de θ), então o EMV será um ponto crítico de $L(\theta)$, isto é, deverá satisfazer

$$\left[\frac{\partial}{\partial \theta} \ell(\theta) \right]_{\theta=\hat{\theta}} = 0.$$

Uma condição suficiente para sabermos se um ponto crítico é um ponto de máxima, e portanto um EMV, é se

$$\left[\frac{\partial^2}{\partial \theta^2} \ell(\theta) \right]_{\theta=\hat{\theta}} < 0.$$

Propriedade da invariância

Invariância: pode-se mostrar que se $\hat{\theta}$ é o EMV de θ , então $g(\hat{\theta})$ é o EMV de $g(\theta)$, em que $g(\cdot)$ é uma função qualquer.

Exemplo 1

Seja $X \sim \text{Bernoulli}(p)$ e $x_1, \dots, x_n$ uma a.a. observada de X . Determine o EMV de p .

- ▶ Função de probabilidade: $f(x; p) = p^x(1-p)^{1-x}$, $x \in \{0, 1\}$
- ▶ Verossimilhança: $L(p) = \prod_{i=1}^n f(x_i; p) = \prod_{i=1}^n p^{x_i}(1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i} = p^{n\bar{x}} (1-p)^{n(1-\bar{x})}$
- ▶ Log-verossimilhança:
 $\ell(p) = \log(L(p)) = n\bar{x} \log p + n(1-\bar{x}) \log(1-p)$
- ▶ Buscando o ponto que maximiza $\ell(p)$:
 - ▶ Derivada em p

$$\frac{d}{dp} \ell(p) = \frac{n\bar{x}}{p} - \frac{n(1-\bar{x})}{1-p}$$

- ▶ Igualando a derivada a zero ($\frac{d}{dp} \ell(p) = 0$), obtemos: $p = \bar{x}$.

Exemplo 1 - continuação

- ▶ Verificando se $p = \bar{x}$ é ponto de máximo

- ▶ Segunda derivada:

$$\frac{d^2}{dp^2}\ell(p) = -\frac{n\bar{x}}{p^2} - \frac{n(1-\bar{x})}{(1-p)^2}$$

- ▶ Vericando em $p = \bar{x}$, temos:

$$-\left(\frac{n}{\bar{x}} + \frac{n}{1-\bar{x}}\right) < 0$$

- ▶ Concluimos então que $\hat{p} = \bar{x}$ é o EMV.

Exemplo 2

Suponha que o tempo de vida (em 1000 horas) das lâmpadas produzidas por uma empresa seja uma v.a. X com a seguinte f.d.p

$$f(x; \theta) = \theta e^{-\theta x}, \quad x \geq 0,$$

em que $\theta > 0$ é um parâmetro desconhecido. Suponha que uma a.a. de 5 lâmpadas obteve os seguintes tempos de vidas 3.5; 6.0; 5.2; 2.1; 4.2. Qual a estimativa de máxima verossimilhança de θ ?

- ▶ Verossimilhança: $L(\theta) = \prod_{i=1}^n f(x_i; \theta) = \theta^n e^{-\theta n \bar{x}}$
- ▶ log-verossimilhança: $\ell(\theta) = n \log(\theta) - n \bar{x} \theta$
- ▶ Primeira derivada: $\frac{d}{d\theta} \ell(\theta) = \frac{n}{\theta} - n \bar{x}$
- ▶ Buscando ponto crítico: $\frac{d}{d\theta} \ell(\theta) = 0 \Rightarrow \hat{\theta} = 1/\bar{x}$
- ▶ Confirmando se é ponto de máximo:
$$\left[\frac{d^2}{d\theta^2} \ell(\theta) \right]_{\theta=\hat{\theta}} = \left[-\frac{n}{\theta^2} \right]_{\theta=\hat{\theta}} = -n \bar{x}^2 < 0 \text{ (OK!)}$$
- ▶ Como $\bar{x} = (3.5 + 6.0 + 5.2 + 2.1 + 4.2)/5 = 4.2$, então $\hat{\theta} = 1/\bar{x} = 1/4.2 = 0.2380952$ é a estimativa de máxima verossimilhança de θ .

Exemplo 3

Para o problema do Exemplo 2, determine qual o EMV para θ^2 e calcule a estimativa.

Solução:

- ▶ Pela propriedade da invariância, temos que o EMV de $g(\theta) = \theta^2$ é $g(\hat{\theta})$, então

$$g(\hat{\theta}) = \hat{\theta}^2 = 1/\bar{x}^2$$

- ▶ Logo a estimativa de θ^2 é $1/4.2^2 = 0.05668934$.

Exercício 1

Seja $X \sim \text{Normal}(\mu, \sigma^2)$, com μ desconhecido e $\sigma^2 = 4$ conhecido. Seja

0.7; 0.1; 0.8; 0.7; 0.3

uma a.a. de X . Mostre que o EMV de μ é $\hat{\mu} = \bar{X}$ e calcule a estimativa.

► Estimativa: $\hat{\mu} = 0.52$

Exercício 2

Seja $X \sim \text{Binomial}(m, p)$, com $m = 6$ conhecido e p desconhecido. Seja

2; 5; 0; 1; 4; 3; 6;

uma a.a. de X . Mostre que o EMV de p é $\hat{p} = \bar{X}/m$ e calcule a estimativa.

► Estimativa: $\hat{p} = 0.5$

Estimação Intervalar (intervalo de confiança)

Resultados importantes (aulas anteriores)

Seja $X_1, \dots, X_n$ uma a.a. de uma população representada pela v.a. X , em que a média populacional é $\mu = E[X]$ e a variância populacional é $\sigma^2 = Var[X]$.

- ▶ Estimadores pontuais usuais

- ▶ $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ é um estimador de μ

- ▶ $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ é um estimador de σ^2

- ▶ Vimos que

- ▶ $E[\bar{X}] = \mu$

- ▶ $Var[\bar{X}] = \sigma^2/n$

- ▶ Se X tem distribuição Normal, então:

$$Z = \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right) \sim Normal(0, 1)$$

- ▶ Se X não tem distribuição Normal, mas n é grande, então (TCL):

$$Z = \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right) \sim^a Normal(0, 1)$$

Distribuição t-Student - Resultado Novo

Def. Nas mesmas condições do slide anterior, se X tem distribuição Normal, então


$$T = \left(\frac{\bar{X} - \mu}{S/\sqrt{n}} \right) \sim t_{(n-1)}$$

em que $t_{(n-1)}$ denota a distribuição de probabilidade **t de Student** com $(n-1)$ graus de liberdade (g.l.).

- ▶ A distribuição **t de Student** foi proposta pelo estatístico inglês W. S. Gosset, que publicou sua pesquisa sob o pseudônimo de “Student”.
- ▶ Note que, a variável T se diferencia da Z apenas por trocar σ (desvio padrão populacional) pelo S (desvio padrão amostral).
- ▶ Esse resultado é importante pois em muitas situações (que serão vistas a frente) o desvio padrão populacional é desconhecido, mas o desvio padrão amostral é sempre conhecido.

Distribuição t-Student - Resultado Novo

- Probabilidades envolvendo a **t de Student** podem ser calculadas utilizando a **tabela da t-Student**.
- A frente será visto como usar e interpretar a tabela da t-Student, que apesar de semelhante a tabela da Normal(0,1), possui algumas peculiaridades.



- Para n grande, a distribuição $t_{(gl=n-1)}$ converge para a Normal(0, 1). Para n pequeno, a distribuição $t_{(gl=n-1)}$ possui mais probabilidade nas caudas que a Normal(0, 1).

Estimação Intervalar - Média Populacional

Intervalo de confiança para a média

- ▶ Seja $X_1, \dots, X_n$ uma a.a. de uma população representada pela v.a. X , em que a média populacional é $\mu = E[X]$ e a variância populacional é $\sigma^2 = \text{Var}[X]$;
- ▶ Escolhida uma probabilidade C conhecida como **nível de confiança** (ou probabilidade de cobertura), o **intervalo de confiança** para a média populacional (μ) é o intervalo (LI, LS) , tal que,

$$C = P[LI < \mu < LS]$$

ou seja, C é a probabilidade do intervalo (LI, LS) conter o real valor da média populacional (se repetido com múltiplas amostras, esse seria o percentual de vezes que o parâmetro estaria dentro do intervalo).

- ▶ LI e LS são chamados respectivamente de **Limite Inferior** e **Limite Superior**, os quais são estatísticas (calculadas a partir da amostra).
- ▶ Usualmente, representamos $C = 1 - \alpha$ em que α é a probabilidade do μ estar fora do intervalo (LI, LS) .


Variância conhecida

- Suponha que a variância populacional (σ^2) seja **conhecida**;
- Dado o nível de confiança $C = 1 - \alpha$, como

$$Z = \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right) \sim^a \text{Normal}(0, 1)$$

podemos obter os quantis $z_{\alpha/2}$ e $z_{1-\alpha/2}$, tais que

$$1 - \alpha = P[z_{\alpha/2} < Z < z_{1-\alpha/2}]$$



- Note que, dado a simetria da Normal, $z_{1-\alpha/2} = -z_{\alpha/2}$.

Variância conhecida

- Assim,

$$\begin{aligned}1 - \alpha &= P \left[-z_{1-\alpha/2} < Z < z_{1-\alpha/2} \right] \\&= P \left[-z_{1-\alpha/2} < \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < z_{1-\alpha/2} \right] \\&= P \left[\bar{X} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right]\end{aligned}$$

- Logo, deduzimos que o limite inferior e o limite superior são dados respectivamente por

$$LI = \bar{X} - E$$

$$LS = \bar{X} + E$$

em que,

$$E = z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$

- Uma vez que $\bar{X}$ é o estimador pontual de μ , a quantidade E é chamada de **Erro Amostral** (ou **Margem de Erro**) do estimador pontual.

Variância conhecida - tamanho da amostra

- ▶ É comum que em um estudo o pesquisador fique em dúvida sobre qual o tamanho da amostra que deve ser coletada para ter níveis razoáveis de confiança na estimação.
- ▶ Se especificado a priori qual o nível desejado da margem de erro (E) e qual a probabilidade de cobertura ($1 - \alpha$), então podemos obter o tamanho necessário da amostra isolando “ n ” na equação anterior, ou seja,

$$n = \left(z_{1-\alpha/2} \frac{\sigma}{E} \right)^2$$

- ▶ Note que a aplicabilidade dessas equações depende do conhecimento prévio da variância populacional (σ^2).

Variância desconhecida

- ▶ Em muitas situações σ^2 é **desconhecido**, o que inviabiliza o uso das equações anteriores;
- ▶ No entanto, a variância amostral (S^2) é conhecida sempre, pois depende apenas da amostra;
- ▶ Nessas situações, podemos utilizar a variável t-Student com $n - 1$ graus de liberdade, pois

$$T = \left(\frac{\bar{X} - \mu}{S/\sqrt{n}} \right) \sim t_{(n-1)}$$

- ▶ Assim, buscaremos quantis $t_{(\alpha/2, n-1)}$ e $t_{(1-\alpha/2, n-1)}$ da distribuição $t_{(n-1)}$, tais que:

$$1 - \alpha = P[t_{(\alpha/2, n-1)} < T < t_{(1-\alpha/2, n-1)}].$$

Variância desconhecida

- ▶ Logo, repetindo o mesmo desenvolvimento feito para o caso de variância conhecida, deduzimos que o limite inferior e o limite superior são dados respectivamente por

$$LI = \bar{X} - E$$

$$LS = \bar{X} + E$$

em que, a erro amostral (ou margem de erro) é dada por

$$E = t_{(1-\alpha/2, n-1)} \frac{S}{\sqrt{n}}.$$

Variância desconhecida - tamanho da amostra

- ▶ Isolando “ n ” na equação do erro amostral, obtemos

$$n = \left(t_{(1-\alpha/2, n-1)} \frac{S}{E} \right)^2$$

no entanto, antes da amostra ser coletada o desvio padrão S não pode ser calculado, bem como o valor de $t_{(1-\alpha/2, n-1)}$ pois a distribuição $t_{(n-1)}$ depende de n .

- ▶ Usualmente, para contornar esse problema, é coletada uma amostra preliminar de tamanho $n_0 > 30$, então é calculada uma variância amostral preliminar (S_0^2).
 - ▶ O valor de $t_{(1-\alpha/2, n-1)}$ é aproximado por $z_{1-\alpha/2}$.
 - ▶ Em seguida, esses valores são utilizados na equação anterior para aproximar o tamanho necessário da amostra.

Exemplo 1 - amostra pequena, dist. Normal, variância conhecida

Em uma indústria de cerveja o volume da bebida inserida em latas tem distribuição Normal. Uma amostra com 20 latas acusou média de 346 ml. Obtenha um intervalo de confiança de 95% para a média global, supondo que o desvio padrão, por analogia a outros produtos, é igual a 3 ml.

Solução:

► Dados:

► $\sigma^2 = 3^2 = 9 \text{ ml}^2$ (**variância conhecida**)

► Amostra: $\bar{x} = 346 \text{ ml}$ e $n = 20$ (amostra pequena e dist. Normal)

► $C = 0.95 \Rightarrow \alpha = 0.05$

► $z_{1-\alpha/2} = z_{0.975}$

► Valor crítico: $0.975 = P[Z < z_{0.975}] \Rightarrow \text{tab. Normal} \quad z_{0.975} = 1.96$

► Erro amostral: $E = z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} = 1.96 \frac{3}{\sqrt{20}} = 1.315 \text{ ml}$

► IC(95%) para μ :

$(\bar{X} - E, \bar{X} + E) \Rightarrow (346 - 1.315, 346 + 1.315) \Rightarrow (344.685, 347.315)$

Exemplo 2 - amostra grande, variância conhecida

Em uma indústria de cerveja o volume da bebida inserida nas latas não possui dist. de probabilidade conhecida. Uma amostra com 40 latas acusou média de 346 ml. Obtenha um intervalo com 95% de confiança para a média global, supondo que o desvio padrão, por analogia a outros produtos, é igual a 3 ml.

Solução:

► Dados:

► $\sigma^2 = 3^2 = 9 \text{ ml}^2$ (**variância conhecida**)

► Amostra: $\bar{x} = 346 \text{ ml}$ e $n = 40$ (amostra grande, aprox. TCL)

► $C = 0.95 \Rightarrow \alpha = 0.05$

► $z_{1-\alpha/2} = z_{0.975}$

► Valor crítico: $0.975 = P[Z < z_{0.975}] \Rightarrow \text{tab. Normal} \quad z_{0.975} = 1.96$

► Erro amostral: $E = z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} = 1.96 \frac{3}{\sqrt{40}} = 0.93 \text{ ml}$

► IC(95%) para μ :

$$(\bar{X} - E, \bar{X} + E) \Rightarrow (346 - 0.93, 346 + 0.93) \Rightarrow (345.07, 346.93)$$

Exemplo 3 - dist. Normal e variância desconhecida

Em uma indústria de cerveja o volume da bebida inserida em latas tem distribuição Normal. Uma amostra com 20 latas acusou média de 346 ml e desvio padrão igual a 4 ml. Obtenha um intervalo de 95% de cobertura para a média global.

Solução:

► Dados:

► $\sigma^2 = ?$ (**variância desconhecida**)

► Amostra: $n = 20$, $\bar{x} = 346 \text{ ml}$ e $S^2 = 4^2 = 16 \text{ ml}^2$

► $C = 0.95 \Rightarrow \alpha = 0.05$

► $t_{(1-\alpha/2, n-1)} = t_{(0.975; 19)}$

► Valor crítico:

$$0.975 = P[T < t_{(0.975; 19)}] \Rightarrow \text{*tab. t-Stud.*} \quad t_{(0.975; 19)} = 2.0930$$

► Erro amostral: $E = t_{(1-\alpha/2, n-1)} \frac{S}{\sqrt{n}} = 2.0930 \frac{4}{\sqrt{20}} = 1.872 \text{ ml}$

► IC(95%) para μ :

$$(\bar{X} - E, \bar{X} + E) \Rightarrow (346 - 1.872, 346 + 1.872) \Rightarrow (344.128, 347.872)$$

Exemplo 4 - tamanho da amostra

Um pesquisador quer estimar o número médio de horas semanais trabalhadas por funcionários de mercearias em uma região. Sabendo que uma amostra preliminar com 30 funcionários revelou o desvio padrão igual a 7.9 horas, determine quantos funcionários devem ser incluídos na amostra para estar 95% confiante que a margem de erro não exceda 1.5 horas?

Solução:

- ▶ Dados: $C = 95\%$; $E = 1.5$; $S_0 = 7.9$
- ▶ Ponto crítico aproximado:
 $t_{(1-\alpha/2, n-1)} = t_{(0.975, n-1)} \approx z_{0.975} = 1.96$
- ▶ Tamanho mínimo da amostra (conservador):

$$n = \left(t_{(1-\alpha/2, n-1)} \frac{S}{E} \right)^2 \approx \left(1.96 * \frac{7.9}{1.5} \right)^2 = 10.32^2 = 106.5024$$

ou seja, são necessários no mínimo 107 funcionários para que a margem de erro não ultrapasse 1.5 horas.

Estimação Intervalar - Proporção Populacional

Proporção populacional - lembrete

- ▶ Se $X \sim \text{Bernoulli}(p)$, então

$$X = \begin{cases} 1 : & \text{se o indivíduo possui a característica} \\ 0 : & \text{se não possui a característica} \end{cases}$$

Além do mais

$$\mu = E[X] = p \quad \text{e} \quad \sigma^2 = \text{Var}[X] = p(1 - p)$$

- ▶ Seja $X_1, \dots, X_n$ uma a.a. de X ,
 - ▶ Estimador pontual usual é a proporção amostral, mas essa é igual a média amostral

$$\hat{p} = \frac{X_1 + \dots + X_n}{n} = \bar{X}$$

- ▶ Pelo TCL, temos que para amostras grandes

$$Z = \left(\frac{\hat{p} - p}{\sigma / \sqrt{n}} \right) \sim^a \text{Normal}(0, 1)$$

em que $\sigma = \sqrt{p(1 - p)}$.

Intervalo de confiança para a proporção populacional

- ▶ Uma vez que a proporção populacional é simplesmente a média populacional de uma variável binária (Bernoulli), temos que o intervalo de confiança, caso σ^2 fosse conhecido, seria dado por:

$$LI = \hat{p} - E$$

$$LS = \hat{p} + E$$

em que,

$$E = z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$

desde que n seja suficientemente grande, uma vez que estamos utilizando o TCL.

- ▶ No entanto, nesse problema sabemos que $\sigma^2 = p(1 - p)$, ou seja, σ^2 depende de p que é o valor que estamos estimando. Desta forma, conhecemos a equação de σ^2 , mas não somos capazes de calcular o valor.
- ▶ Existem duas abordagens para contornar esse problema: **otimista** e **conservadora**;

Intervalo de confiança para a proporção populacional

- **Abordagem Otimista:** uma vez que a proporção amostral ($\hat{p}$) é conhecida, podemos aproximar $\sigma^2 = p(1 - p)$ por sua estimativa, isto é, $\hat{\sigma}^2 = \hat{p}(1 - \hat{p})$. Neste caso, a margem de erro é adotada como sendo

$$E = z_{1-\alpha/2} \frac{\hat{\sigma}}{\sqrt{n}} = z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

- **Abordagem Conservadora:** como $\sigma^2 = p(1 - p)$ e $p \in (0, 1)$ é fácil ver que a variância é uma função limitada com valor máximo igual a 0.25, isto é, $p(1 - p) \leq 0.25, \forall p \in (0, 1)$. Assim, de modo conservador, adotamos o valor máximo da variância para calcular a margem de erro:

$$E = z_{1-\alpha/2} \frac{\sqrt{0.25}}{\sqrt{n}} = z_{1-\alpha/2} \frac{0.5}{\sqrt{n}}$$

Intervalo de confiança para a proporção - tamanho de amostra

Dado o nível de confiança ($C = 1 - \alpha$) e um valor máximo pra margem de erro (E), o tamanho mínimo necessário para a amostra geralmente é calculado isolando “ n ” na equação da margem de erro.

► Abordagem otimista

$$n = \left(z_{1-\alpha/2} \frac{\sqrt{\tilde{p}(1-\tilde{p})}}{E} \right)^2$$

- **OBS:** neste caso, $\tilde{p}$ faz referência a proporção amostral de um estudo anterior (ou preliminar).

► Abordagem conservadora

$$n = \left(z_{1-\alpha/2} \frac{0.5}{E} \right)^2$$

Exemplo 1

Uma pesquisa eleitoral ouviu 600 eleitores escolhidos de forma aleatória. Cem dessas pessoas responderam que pretendem votar no candidato A. Qual a estimativa pontual e intervalar da intenção de votos em A? Considere nível de confiança de 95%.

Solução:

- ▶ Amostra

$$n = 600$$

$$\hat{p} = \frac{100}{600} \approx 0.17 \quad (\text{estimativa pontual})$$

- ▶ Nível de confiança: 95%

$$C = 0.95 \Rightarrow \alpha = 0.05 \Rightarrow z_{1-\alpha/2} = z_{0.975} = 1.96$$

Exemplo 1- continuação

- ▶ Intervalo de confiança **otimista**

- ▶ Margem de erro:

$$E = z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = 1.96 \sqrt{\frac{0.17 * (1 - 0.17)}{600}} = 0.03$$

- ▶ IC (95%):

$$\begin{aligned} IC(95\%) : (\hat{p} - E, \hat{p} + E) \\ : (0.17 - 0.03, 0.17 + 0.03) \\ : (0.14, 0.20) \end{aligned}$$

- ▶ A pesq. revelou 17% de intenção de votos, a margem de erro é de 3 pontos percentuais para mais ou para menos. A probabilidade da pesquisa revelar a real intenção de votos é de 95%.

Exemplo 1- continuação

- ▶ Intervalo de confiança **conservador**

- ▶ Margem de erro:

$$E = z_{1-\alpha/2} \frac{0.5}{\sqrt{n}} = 1.96 \frac{0.5}{\sqrt{600}} \approx 0.04$$

- ▶ IC (95%):

$$\begin{aligned} IC(95\%) : (\hat{p} - E, \hat{p} + E) \\ : (0.17 - 0.04, 0.17 + 0.04) \\ : (0.13, 0.21) \end{aligned}$$

- ▶ A pesq. revelou 17% de intenção de votos, a margem de erro é de 4 pontos percentuais para mais ou para menos. A probabilidade da pesquisa revelar a real intenção de votos é de 95%.

Exemplo 2

Com 95% de confiança, determine o tamanho mínimo da amostra para garantir que a margem de erro de uma pesquisa eleitoral não ultrapasse 2 pontos percentuais. Sabendo que uma pesquisa preliminar obteve $\tilde{p} = 0.2$, utilize a abordagem otimista.

Solução:

► Dados

► $C = 0.95 \Rightarrow \alpha = 0.05 \Rightarrow z_{0.975} = 1.96$

► $E=0.02$

► Tamanho mínimo da amostra

$$n = \left(z_{1-\alpha/2} \frac{\sqrt{\tilde{p}(1-\tilde{p})}}{E} \right)^2 = \left(1.96 \frac{\sqrt{0.2(1-0.2)}}{0.02} \right)^2 = 1536.64$$

- Assim, são necessárias 1537 pessoas para que a margem de erro otimista seja de 2 pontos percentuais.

Exemplo 3

Com 95% de confiança, determine o tamanho mínimo da amostra para garantir que a margem de erro de uma pesquisa eleitoral não ultrapasse 2 pontos percentuais. Utilize a abordagem conservadora.

Solução:

► Dados

► $C = 0.95 \Rightarrow \alpha = 0.05 \Rightarrow z_{0.975} = 1.96$

► $E=0.02$

► Tamanho mínimo da amostra

$$n = \left(z_{1-\alpha/2} \frac{0.5}{E} \right)^2 = \left(1.96 \frac{0.5}{0.02} \right)^2 = 2401$$

- Assim, são necessárias 2401 pessoas para que a margem de erro conservadora seja de 2 pontos percentuais.
- Pesquisas eleitorais tradicionais costumam utilizar a abordagem conservadora e arredondar para 2500 pessoas.