EST0023 - PROBABILIDADE E ESTATÍSTICA

Unidade I - Introdução

José Augusto Fiorucci

Departamento de Estatística
Universidade de Brasília

Estatística

- **Definição**: estatística é a ciência que trata da coleta, organização, análise e interpretação de dados para tomada de decisões.
  - Os dados são obtidos a partir de uma amostra da população.
- **População**: coleção de todos os dados de interesse
  - geralmente desconhecido como um todo
- **Amostra**: subconjunto da população
  - parte da população que é conhecida
  - na disciplina estaremos interessados em estudar apenas **amostra aleatória**
    - obtida de forma aleatória (ex: sorteio)
    - todos os elementos da população tem a mesma chance de entrar na amostra

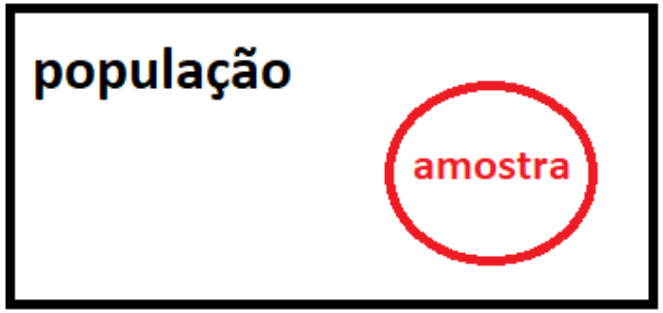

Estatística

- **Definição**: estatística é a ciência que trata da coleta, organização, análise e interpretação de dados para tomada de decisões.
  - Os dados são obtidos a partir de uma amostra da população.
- **População**: coleção de todos os dados de interesse
  - geralmente desconhecido como um todo
- **Amostra**: subconjunto da população
  - parte da população que é conhecida
  - na disciplina estaremos interessados em estudar apenas **amostra aleatória**
    - obtida de forma aleatória (ex: sorteio)
    - todos os elementos da população tem a mesma chance de entrar na amostra

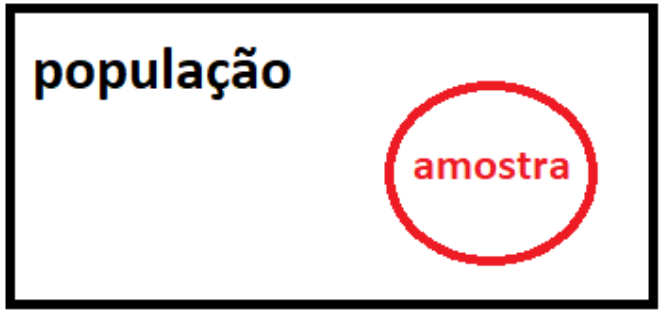

Estatística

- **Definição**: estatística é a ciência que trata da coleta, organização, análise e interpretação de dados para tomada de decisões.
  - Os dados são obtidos a partir de uma amostra da população.
- **População**: coleção de todos os dados de interesse
  - geralmente desconhecido como um todo
- **Amostra**: subconjunto da população
  - parte da população que é conhecida
  - na disciplina estaremos interessados em estudar apenas **amostra aleatória**
    - obtida de forma aleatória (ex: sorteio)
    - todos os elementos da população tem a mesma chance de entrar na amostra

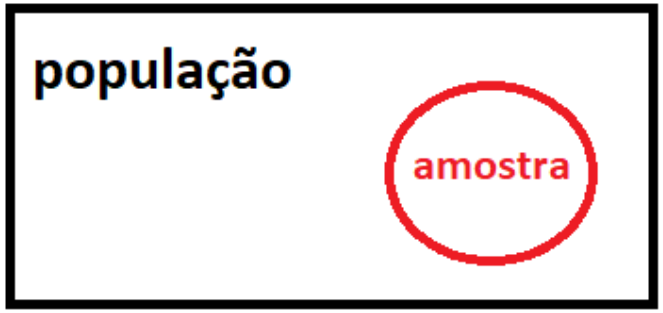

- **Estatística descritiva**: conjunto de técnicas para descrever dados (medidas e gráficos)

- Exemplo: em uma pesquisa recente foi perguntado a 614 proprietários de pequenas empresas no DF se eles acreditavam que a presença de sua empresa no facebook agregava algum valor pro seu negócio. Desses 258 responderam sim e os demais responderam não.
  - População: todos os pequenos empresários do DF
  - Amostra: 614 ouvidos na pesquisa
  - Estatística descritiva:
    - percentual da amostra que responderam sim: $\frac{258}{614} = 42\%$
    - percentual da amostra que responderam não: $\frac{356}{614} = 58\%$

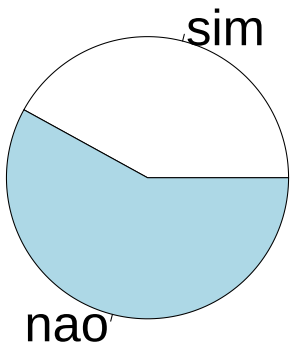

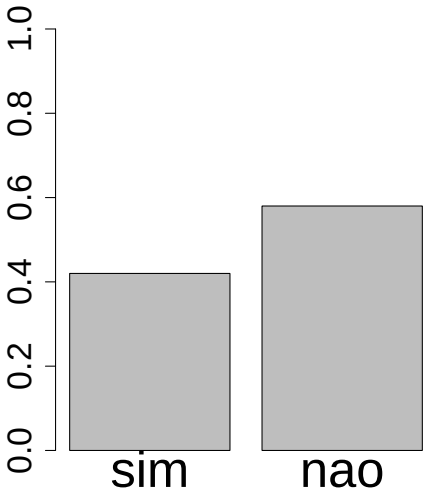

- **Estatística descritiva**: conjunto de técnicas para descrever dados (medidas e gráficos)

- Exemplo: em uma pesquisa recente foi perguntado a 614 proprietários de pequenas empresas no DF se eles acreditavam que a presença de sua empresa no facebook agregava algum valor pro seu negócio. Desses 258 responderam sim e os demais responderam não.
  - População: todos os pequenos empresários do DF
  - Amostra: 614 ouvidos na pesquisa
  - Estatística descritiva:
    - percentual da amostra que responderam sim: $\frac{258}{614} = 42\%$
    - percentual da amostra que responderam não: $\frac{356}{614} = 58\%$

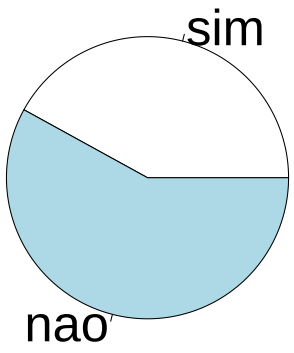

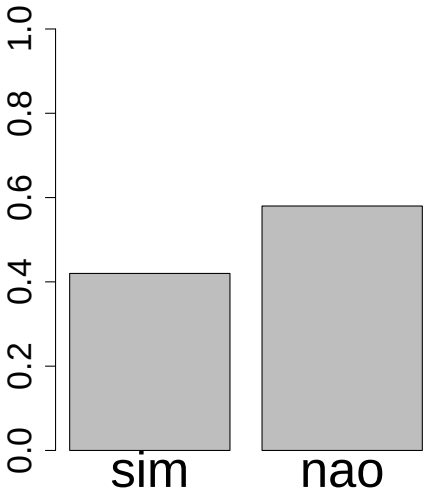

- **Estatística descritiva**: conjunto de técnicas para descrever dados (medidas e gráficos)

- Exemplo: em uma pesquisa recente foi perguntado a 614 proprietários de pequenas empresas no DF se eles acreditavam que a presença de sua empresa no facebook agregava algum valor pro seu negócio. Desses 258 responderam sim e os demais responderam não.
  - População: todos os pequenos empresários do DF
  - Amostra: 614 ouvidos na pesquisa
  - Estatística descritiva:
    - percentual da amostra que responderam sim: $\frac{258}{614} = 42\%$
    - percentual da amostra que responderam não: $\frac{356}{614} = 58\%$

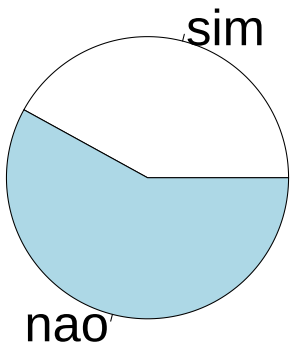

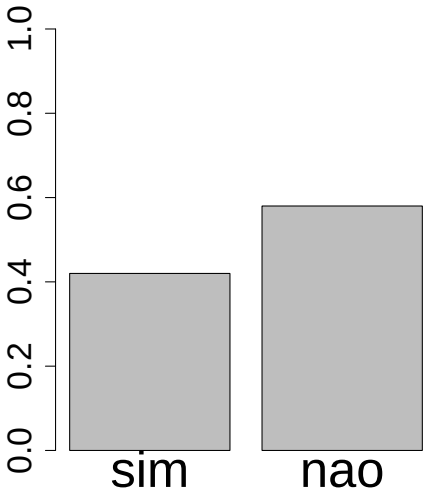

- **Estatística descritiva**: conjunto de técnicas para descrever dados (medidas e gráficos)

- Exemplo: em uma pesquisa recente foi perguntado a 614 proprietários de pequenas empresas no DF se eles acreditavam que a presença de sua empresa no facebook agregava algum valor pro seu negócio. Desses 258 responderam sim e os demais responderam não.
  - População: todos os pequenos empresários do DF
  - Amostra: 614 ouvidos na pesquisa
  - Estatística descritiva:
    - percentual da amostra que responderam sim: $\frac{258}{614} = 42\%$
    - percentual da amostra que responderam não: $\frac{356}{614} = 58\%$

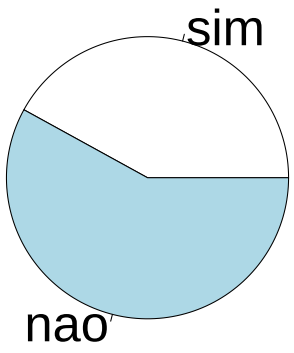

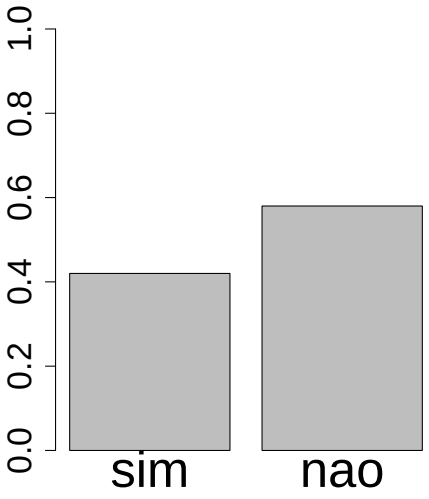

- **Estatística descritiva**: conjunto de técnicas para descrever dados (medidas e gráficos)

- Exemplo: em uma pesquisa recente foi perguntado a 614 proprietários de pequenas empresas no DF se eles acreditavam que a presença de sua empresa no facebook agregava algum valor pro seu negócio. Desses 258 responderam sim e os demais responderam não.
  - População: todos os pequenos empresários do DF
  - Amostra: 614 ouvidos na pesquisa
  - Estatística descritiva:
    - percentual da amostra que responderam sim: $\frac{258}{614} = 42\%$
    - percentual da amostra que responderam não: $\frac{356}{614} = 58\%$

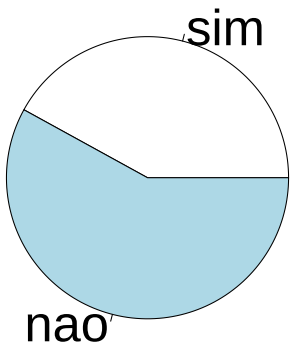

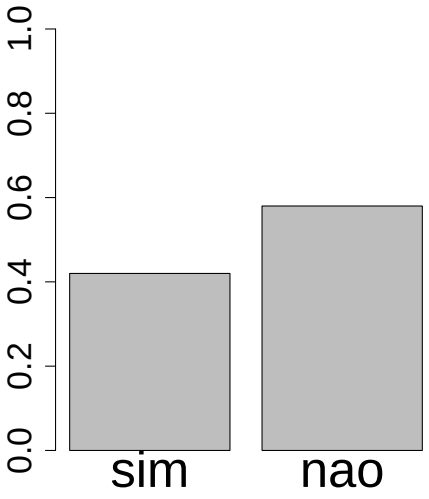

- **Estatística descritiva**: conjunto de técnicas para descrever dados (medidas e gráficos)

- Exemplo: em uma pesquisa recente foi perguntado a 614 proprietários de pequenas empresas no DF se eles acreditavam que a presença de sua empresa no facebook agregava algum valor pro seu negócio. Desses 258 responderam sim e os demais responderam não.
  - População: todos os pequenos empresários do DF
  - Amostra: 614 ouvidos na pesquisa
  - Estatística descritiva:
    - percentual da amostra que responderam sim: $\frac{258}{614} = 42\%$
    - percentual da amostra que responderam não: $\frac{356}{614} = 58\%$

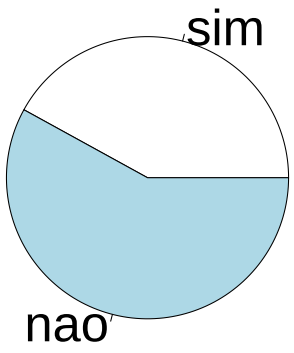

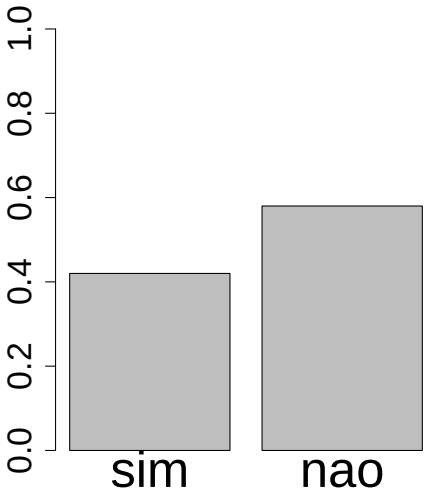

- **Estatística descritiva**: conjunto de técnicas para descrever dados (medidas e gráficos)

- Exemplo: em uma pesquisa recente foi perguntado a 614 proprietários de pequenas empresas no DF se eles acreditavam que a presença de sua empresa no facebook agregava algum valor pro seu negócio. Desses 258 responderam sim e os demais responderam não.
  - População: todos os pequenos empresários do DF
  - Amostra: 614 ouvidos na pesquisa
  - Estatística descritiva:
    - percentual da amostra que responderam sim: $\frac{258}{614} = 42\%$
    - percentual da amostra que responderam não: $\frac{356}{614} = 58\%$

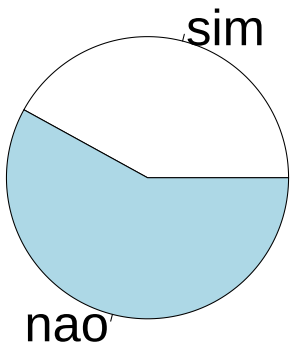

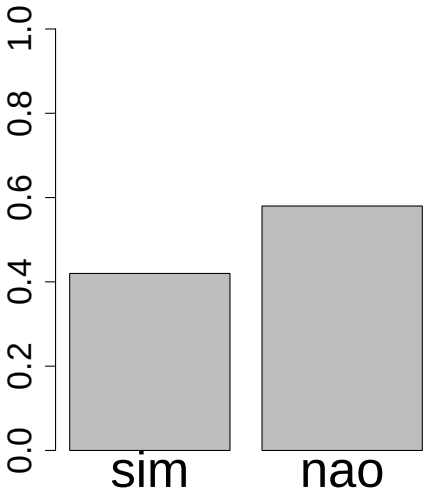

- **Estatística descritiva**: conjunto de técnicas para descrever dados (medidas e gráficos)

- Exemplo: em uma pesquisa recente foi perguntado a 614 proprietários de pequenas empresas no DF se eles acreditavam que a presença de sua empresa no facebook agregava algum valor pro seu negócio. Desses 258 responderam sim e os demais responderam não.
  - População: todos os pequenos empresários do DF
  - Amostra: 614 ouvidos na pesquisa
  - Estatística descritiva:
    - percentual da amostra que responderam sim: $\frac{258}{614} = 42\%$
    - percentual da amostra que responderam não: $\frac{356}{614} = 58\%$

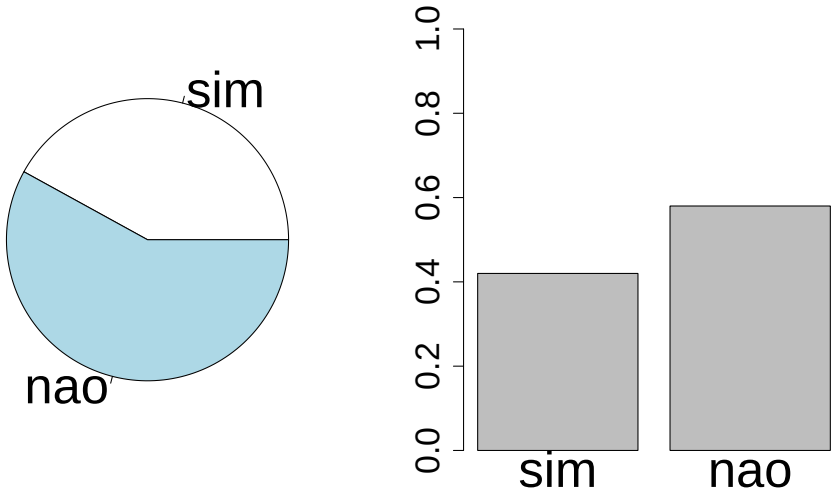

- **Amostragem**: processo no qual a amostra é coletada de forma a obter uma parte representativa da população;
- **Inferência estatística**: refere-se ao uso apropriado de uma amostra para se gerar conhecimento sobre a população;

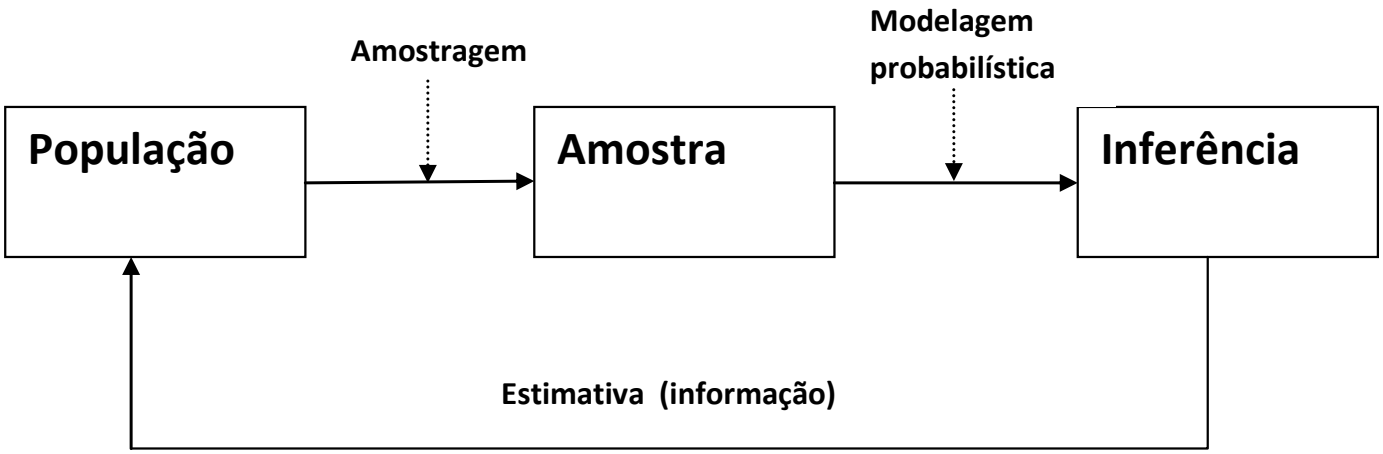

Principais medidas descritivas

Seja $x_1, x_2, \ldots, x_n$ uma amostra de tamanho n.

- Média amostral: descreve o ponto de equilíbrio da amostra, geralmente denotada com uma barra sobre a variável ($\bar{x}$):

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

- Mediana: consiste no valor central dos dados ordenados, isto é, este é o ponto em que metade dos dados é menor ou igual a ele e a outra metade é maior ou igual a ele. Vamos denotar a mediana por M, então se $x_{(1)}, x_{(2)}, \ldots, x_{(n)}$ é o conjunto de dados ordenado, então a mediana amostral é definida como:
  - se n é impar, então $M = x_{(m)}$, em que $m = (n-1)/2 + 1$;
  - se n é par, então $M = (x_{(m)} + x_{(m+1)})/2$, em que $m = n/2$;

Principais medidas descritivas

Seja $x_1, x_2, \ldots, x_n$ uma amostra de tamanho n.

- Média amostral: descreve o ponto de equilíbrio da amostra, geralmente denotada com uma barra sobre a variável ($\bar{x}$):

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

- Mediana: consiste no valor central dos dados ordenados, isto é, este é o ponto em que metade dos dados é menor ou igual a ele e a outra metade é maior ou igual a ele. Vamos denotar a mediana por M, então se $x_{(1)}, x_{(2)}, \ldots, x_{(n)}$ é o conjunto de dados ordenado, então a mediana amostral é definida como:
  - se n é impar, então $M = x_{(m)}$, em que $m = (n-1)/2 + 1$;
  - se n é par, então $M = (x_{(m)} + x_{(m+1)})/2$, em que $m = n/2$;

Principais medidas descritivas

Seja $x_1, x_2, \ldots, x_n$ uma amostra de tamanho n.

- Média amostral: descreve o ponto de equilíbrio da amostra, geralmente denotada com uma barra sobre a variável ($\bar{x}$):

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

- Mediana: consiste no valor central dos dados ordenados, isto é, este é o ponto em que metade dos dados é menor ou igual a ele e a outra metade é maior ou igual a ele. Vamos denotar a mediana por M, então se $x_{(1)}, x_{(2)}, \ldots, x_{(n)}$ é o conjunto de dados ordenado, então a mediana amostral é definida como:
  - se n é impar, então $M = x_{(m)}$, em que $m = (n-1)/2 + 1$;
  - se n é par, então $M = (x_{(m)} + x_{(m+1)})/2$, em que $m = n/2$;

Principais medidas descritivas

- Variância amostral: descreve o nível de dispersão dos dados em relação a média na escala quadrática, geralmente denotada por S^2:

$$S^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \cdots + (x_n - \bar{x})^2}{n-1} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

- Desvio Padrão amostral: descreve o nível de dispersão dos dados em relação a média na escala original, geralmente denotado por S:

$$S = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

Principais medidas descritivas

- Variância amostral: descreve o nível de dispersão dos dados em relação a média na escala quadrática, geralmente denotada por S^2:

$$S^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \cdots + (x_n - \bar{x})^2}{n-1} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

- Desvio Padrão amostral: descreve o nível de dispersão dos dados em relação a média na escala original, geralmente denotado por S:

$$S = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

- Exemplo: suponha que 7 alunos da turma foram sorteados para formar uma amostra das idades dos alunos. As idades observadas foram $20, 19, 21, 23, 22, 18, 20$.
  - Média amostral: $\bar{x} = \frac{x_1+x_2+\cdots+x_7}{7} = 143/7 \quad \approx 20.43$ anos;
  - Mediana: como $n = 7$ então $M = x_{(4)}$. Ordenando os dados, temos $18, 19, 20, 20, 21, 22, 23$ e portanto $M = 20$ anos;
  - Variância amostral:

$$S^2 = \frac{1}{6}\sum_{i=1}^{7}(x_i - \bar{x})^2 = [\ (-0.43)^2 + (-1.43)^2 + (0.57)^2 + (2.57)^2 + (1.57)^2 + (-2.43)^2 + (-0.43)^2\ ]/6 \quad \approx 2.95 \text{ anos}^2$$

  - Desvio padrão amostral: $S = \sqrt{2.95} \quad \approx 1.72$ anos

- Exemplo: suponha que 7 alunos da turma foram sorteados para formar uma amostra das idades dos alunos. As idades observadas foram $20, 19, 21, 23, 22, 18, 20$.

  - Média amostral: $\bar{x} = \frac{x_1+x_2+\cdots+x_7}{7} = 143/7 \quad \approx 20.43$ anos;

  - Mediana: como $n = 7$ então $M = x_{(4)}$. Ordenando os dados, temos $18, 19, 20, 20, 21, 22, 23$ e portanto $M = 20$ anos;

  - Variância amostral:

$$S^2 = \frac{1}{6}\sum_{i=1}^{7}(x_i - \bar{x})^2 = [\ (-0.43)^2 + (-1.43)^2 + (0.57)^2 + (2.57)^2 + (1.57)^2 + (-2.43)^2 + (-0.43)^2\ ]/6 \quad \approx 2.95 \text{ anos}^2$$

  - Desvio padrão amostral: $S = \sqrt{2.95} \quad \approx 1.72$ anos

- Exemplo: suponha que 7 alunos da turma foram sorteados para formar uma amostra das idades dos alunos. As idades observadas foram $20, 19, 21, 23, 22, 18, 20$.

  - Média amostral: $\bar{x} = \frac{x_1+x_2+\cdots+x_7}{7} = 143/7 \quad \approx 20.43$ anos;

  - Mediana: como $n = 7$ então $M = x_{(4)}$. Ordenando os dados, temos $18, 19, 20, 20, 21, 22, 23$ e portanto $M = 20$ anos;

  - Variância amostral:

$$S^2 = \frac{1}{6}\sum_{i=1}^{7}(x_i - \bar{x})^2 = [\ (-0.43)^2 + (-1.43)^2 + (0.57)^2 + (2.57)^2 + (1.57)^2 + (-2.43)^2 + (-0.43)^2\ ]/6 \quad \approx 2.95 \text{ anos}^2$$

  - Desvio padrão amostral: $S = \sqrt{2.95} \quad \approx 1.72$ anos

- Exemplo: suponha que 7 alunos da turma foram sorteados para formar uma amostra das idades dos alunos. As idades observadas foram $20, 19, 21, 23, 22, 18, 20$.

  - Média amostral: $\bar{x} = \frac{x_1+x_2+\cdots+x_7}{7} = 143/7 \quad \approx 20.43$ anos;

  - Mediana: como $n = 7$ então $M = x_{(4)}$. Ordenando os dados, temos $18, 19, 20, 20, 21, 22, 23$ e portanto $M = 20$ anos;

  - Variância amostral:

$$S^2 = \frac{1}{6}\sum_{i=1}^{7}(x_i - \bar{x})^2 = [\ (-0.43)^2 + (-1.43)^2 + (0.57)^2 + (2.57)^2 + (1.57)^2 + (-2.43)^2 + (-0.43)^2\ ]/6 \quad \approx 2.95 \text{ anos}^2$$

  - Desvio padrão amostral: $S = \sqrt{2.95} \quad \approx 1.72$ anos

Exercício:

Repita o exemplo anterior substituindo o valor 23 da amostra pelo valor 80.

- Note que a média, a variância e o desvio padrão serão fortemente afetados, no entanto, a mediana ainda dará o mesmo valor de antes.
- Uma das principais características da mediana é a de não sofrer influência de valores atípicos.